

AniData Lab

Observatoire intelligent du marché Anime / Manga

SYLLABUS DE FORMATION

Semaine du 23 au 27 mars 2026

Durée totale : 31,5 heures (9 créneaux de 3h30)

Niveau : B2

Mode de travail : Binômes

Modules : Data Refinement • Big Data - ELK • ETL & Pipelines (Airflow)

1. Présentation du projet fil rouge	3
1.1 Contexte	3
1.2 Objectif global	3
1.3 Dataset utilisé	3
1.4 Stack technique	3
1.5 Livrable final	3
2. Planning global de la semaine	4
3. Détail des séances	5
Séance 1 — Lundi 23/03 (13h30 - 17h00)	5
Séance 2 — Mardi 24/03 (09h00 - 12h30)	5
Séance 3 — Mardi 24/03 (13h30 - 17h00)	6
Séance 4 — Mercredi 25/03 (09h00 - 12h30)	6
Séance 5 — Mercredi 25/03 (13h30 - 17h00)	6
Séance 7 — Jeudi 26/03 (13h30 - 17h00)	7
Séance 8 — Vendredi 27/03 (09h00 - 12h30)	8
4. Compétences visées	8
4.1 Data Refinement	8
4.2 Big Data — ELK	9
4.3 ETL & Pipelines (Apache Airflow)	9
5. Modalités d'évaluation	9
6. Prérequis	9
7. Ressources & liens utiles	9

1. Présentation du projet fil rouge

1.1 Contexte

Les apprenants incarnent des data engineers au sein d'un studio d'animation japonais fictif, « Sakura Analytics », qui souhaite comprendre les tendances du marché anime et manga mondial. À partir des données brutes issues de MyAnimeList (109 millions de ratings, 17 500 animes, 325 000 utilisateurs), ils construiront une plateforme data complète de bout en bout.

1.2 Objectif global

Construire un pipeline de données automatisé qui extrait, nettoie, transforme et charge les données dans un moteur de recherche et de visualisation, permettant au studio de prendre des décisions stratégiques basées sur les données.

1.3 Dataset utilisé

Source : MyAnimeList Database (Kaggle / GitHub — Hernan4444)

- anime.csv : 17 562 animes (genres, studios, scores, statuts, épisodes, durée...)
- rating_complete.csv : 57 millions de ratings (animes complétés et notés par 310 059 utilisateurs)
- anime_with_synopsis.csv : synopsis textuels de chaque anime
- animelist.csv : 109 millions de lignes (toutes les interactions utilisateurs)

1.4 Stack technique

Composant	Technologie
Langage	Python 3.10+
Manipulation données	Pandas, NumPy
Exploration	VS Code, pandas-profiling
Big Data / Recherche	Elasticsearch, Logstash, Grafana (ELK 8.x)
Orchestration ETL	Apache Airflow 2.x
Conteneurisation	Docker, Docker Compose

1.5 Livrable final

Chaque binôme livrera :

1. Un pipeline Airflow complet (Extract → Transform → Load) déclenchable en un clic
2. Un dashboard Grafana interactif qui se met à jour automatiquement après chaque run
3. Un DAG de détection d'anomalies dans les données
4. Une soutenance orale avec démo live (10 minutes par binôme)

2. Planning global de la semaine

Créneau	Contenu	Module / Durée
Lundi 23/03		
APREM	Audit & Découverte du dataset brut	Data Refinement
13h30 - 17h00		3h30
Mardi 24/03		
MATIN	Nettoyage, enrichissement & Feature Engineering	Data Refinement
09h00 - 12h30		3h30
Mardi 24/03		
APREM	Découverte de la stack ELK & Indexation	Big Data - ELK
13h30 - 17h00		3h30
Mercredi 25/03		
MATIN	Introduction à Apache Airflow & Premier DAG	ETL & Pipelines
09h00 - 12h30		3h30
Mercredi 25/03		
APREM	Pipeline Extract : lecture multi-fichiers & validation	ETL & Pipelines
13h30 - 17h00		3h30
Jeudi 26/03		
MATIN	Pipeline Transform : nettoyage & feature engineering automatisés	ETL & Pipelines
09h00 - 12h30		3h30
Jeudi 26/03		
APREM	Pipeline Load : indexation Elasticsearch & monitoring	ETL & Pipelines
13h30 - 17h00		3h30
Vendredi 27/03		
MATIN	Pipeline avancé : détection d'anomalies & bonnes pratiques	ETL & Pipelines
09h00 - 12h30		3h30
Vendredi 27/03		
APREM	Soutenance & Démo finale	ETL & Pipelines
13h30 - 17h00		3h30

3. Détail des séances

Séance 1 — Lundi 23/03 (13h30 - 17h00)

Module : Data Refinement | **Thème :** Audit & Découverte du dataset brut

Objectifs pédagogiques

- Découvrir le projet fil rouge AniData Lab et le contexte métier
- Explorer le dataset MyAnimeList (anime.csv, rating_complete.csv, anime_with_synopsis.csv)
- Identifier les problèmes de qualité : valeurs manquantes, doublons, types incohérents, encodages japonais
- Réaliser un audit de qualité avec Pandas (profiling, statistiques descriptives)
- Documenter les anomalies dans un rapport d'audit

Activités

1. Présentation du projet et constitution des binômes
2. Chargement et première exploration des 3 fichiers CSV
3. Atelier : audit qualité avec pandas-profiling
4. Livrable : rapport d'audit qualité par binôme

Outils & technologies

Python, Pandas, VS Code, pandas-profiling

Livrable de la séance

Rapport d'audit qualité du dataset brut (Notebook annoté)

Séance 2 — Mardi 24/03 (09h00 - 12h30)

Module : Data Refinement | **Thème :** Nettoyage, enrichissement & Feature Engineering

Objectifs pédagogiques

- ✓ Appliquer les techniques de nettoyage identifiées lors de l'audit
- ✓ Traiter les caractères spéciaux et encodages UTF-8 (titres japonais/coréens)
- ✓ Normaliser les types de données (dates, catégories, numériques)
- ✓ Créer des features métier : score de popularité pondéré, ratio dropped/completed, classification studios
- ✓ Exporter un dataset « gold » propre et enrichi

Activités

1. TP nettoyage : suppression doublons, imputation, correction types
2. TP encodage : gestion des caractères spéciaux dans les titres
3. Atelier feature engineering : création de métriques métier
4. Export du dataset gold en CSV et JSON

Outils & technologies

Python, Pandas, NumPy, VS Code

Livrable de la séance

Dataset « gold » nettoyé et enrichi (CSV + JSON) prêt pour ELK

Séance 3 — Mardi 24/03 (13h30 - 17h00)

Module : Big Data - ELK | Thème : Découverte de la stack ELK & Indexation

Objectifs pédagogiques

- Comprendre l'architecture Elasticsearch / Logstash / Grafana
- Installer et configurer la stack ELK (Docker)
- Créer un index Elasticsearch avec mapping adapté aux données anime
- Indexer le dataset gold via Logstash (pipeline CSV → Elasticsearch)
- Réaliser des requêtes de recherche full-text sur les synopsis

Activités

1. Cours : architecture ELK et cas d'usage Big Data
2. TP : déploiement ELK via Docker Compose
3. TP : création du mapping et indexation avec Logstash
4. Premiers dashboards Grafana : top studios, répartition genres, heatmap ratings

Outils & technologies

Elasticsearch, Logstash, Grafana, Docker, Docker Compose

Livrable de la séance

Stack ELK opérationnelle avec données indexées + 3 visualisations Grafana

Séance 4 — Mercredi 25/03 (09h00 - 12h30)

Module : ETL & Pipelines | Thème : Introduction à Apache Airflow & Premier DAG

Objectifs pédagogiques

- ✓ Comprendre les concepts fondamentaux : DAG, Task, Operator, Schedule, XCom
- ✓ Installer Airflow (Docker ou pip) et découvrir l'interface web
- ✓ Créer un premier DAG « hello_anidata » avec PythonOperator
- ✓ Comprendre le cycle de vie d'un DAG (parsing, scheduling, execution)
- ✓ Créer un DAG d'extraction qui lit les fichiers CSV bruts

Activités

1. Cours : concepts ETL et introduction à Airflow
2. TP : installation Airflow + exploration de l'UI
3. TP : DAG hello_anidata (log, branchement simple, paramètres)
4. TP : DAG extract_anime qui charge les CSV et valide le schéma

Outils & technologies

Apache Airflow, Python, Docker

Livrable de la séance

2 DAGs fonctionnels : hello_anidata + extract_anime

Séance 5 — Mercredi 25/03 (13h30 - 17h00)

Module : ETL & Pipelines | Thème : Pipeline Extract : lecture multi-fichiers & validation

Objectifs pédagogiques

- ✓ Structurer un DAG multi-tasks avec dépendances
- ✓ Implémenter l'extraction de plusieurs sources (anime, ratings, synopsis)
- ✓ Ajouter de la validation de schéma (types, colonnes obligatoires)
- ✓ Gérer les erreurs et les retries dans Airflow
- ✓ Utiliser les XComs pour passer des données entre tasks

Activités

1. Cours : orchestration de tasks et gestion des erreurs
2. TP : DAG extract complet avec 3 tasks d'extraction parallèles
3. TP : ajout de la validation de schéma avec task dédiée
4. TP : gestion des retries et notifications d'échec

Outils & technologies

Apache Airflow, PythonOperator, XCom

Livrable de la séance

DAG Extract complet avec validation et gestion d'erreurs

Séance 6 — Jeudi 26/03 (09h00 - 12h30)

Module : ETL & Pipelines | Thème : Pipeline Transform : nettoyage & feature engineering automatisés

Objectifs pédagogiques

- Intégrer le code de nettoyage (lundi/mardi) dans des tasks Airflow
- Utiliser le BranchPythonOperator pour la logique conditionnelle
- Modulariser les transformations en fonctions réutilisables
- Implémenter un système de versioning du dataset (gold_v1, gold_v2...)
- Tester les transformations avec des jeux de données réduits

Activités

1. Cours : patterns de transformation et branchement conditionnel
2. TP : refactoring du code de nettoyage en modules Python
3. TP : DAG Transform avec BranchPythonOperator
4. TP : ajout du versioning et tests sur données réduites

Outils & technologies

Apache Airflow, BranchPythonOperator, Pandas, Python modules

Livrable de la séance

DAG Transform avec branchement conditionnel et versioning

Séance 7 — Jeudi 26/03 (13h30 - 17h00)

Module : ETL & Pipelines | Thème : Pipeline Load : indexation Elasticsearch & monitoring

Objectifs pédagogiques

- Connecter Airflow à Elasticsearch (Connection, Hook)
- Automatiser l'indexation du dataset gold dans Elasticsearch
- Vérifier que les dashboards Grafana se mettent à jour automatiquement
- Mettre en place le monitoring du DAG (logs, durées, alertes)
- Assembler le pipeline E-T-L complet de bout en bout

Activités

1. Cours : connections Airflow et intégration avec des services externes
2. TP : task Load avec indexation bulk Elasticsearch
3. TP : assemblage du DAG complet (Extract → Transform → Load)
4. TP : monitoring et alertes dans l'UI Airflow

Outils & technologies

Apache Airflow, Elasticsearch, Grafana, elasticsearch-py

Livrable de la séance

Pipeline ETL complet intégré + dashboards Grafana mis à jour automatiquement

Séance 8 — Vendredi 27/03 (09h00 - 12h30)

Module : ETL & Pipelines | Thème : Pipeline avancé : détection d'anomalies & bonnes pratiques

Objectifs pédagogiques

- Créer un DAG de détection d'anomalies (ratings suspects, spam de notes)
- Implémenter le scheduling et le backfill
- Appliquer les bonnes pratiques de production (idempotence, atomicité)
- Gérer les dépendances entre DAGs (TriggerDagRunOperator)
- Préparer la démo finale

Activités

1. Cours : bonnes pratiques Airflow en production
2. TP : DAG anomaly_detector avec règles métier
3. TP : scheduling, backfill et inter-dépendances de DAGs
4. Préparation de la soutenance : tests, nettoyage du code, documentation

Outils & technologies

Apache Airflow, TriggerDagRunOperator, Sensors

Livrable de la séance

DAG de détection d'anomalies + pipeline prêt pour la démo

Séance 9 — Vendredi 27/03 (13h30 - 17h00)

Module : ETL & Pipelines | Thème : Soutenance & Démo finale

Objectifs pédagogiques

- Présenter le pipeline complet devant le groupe (5-10 min par binôme)
- Déclencher un run Airflow en live et observer le dashboard Grafana se mettre à jour
- Justifier les choix techniques (architecture, outils, patterns)
- Répondre aux questions du formateur et des pairs
- Faire un bilan des compétences acquises sur la semaine

Activités

1. Soutenance : présentation + démo live par binôme
2. Questions / réponses et feedback croisé
3. Débriefing collectif et bilan de compétences
4. Perspectives : qu'est-ce qu'on pourrait ajouter ? (ML, streaming, API...)

Outils & technologies

Tout le stack : Python, Airflow, ELK, Docker

Livrable de la séance

Soutenance orale + Pipeline complet fonctionnel + Dashboard Grafana interactif

4. Compétences visées

4.1 Data Refinement

- Auditer un jeu de données brut et identifier les problèmes de qualité
- Nettoyer, normaliser et enrichir des données avec Pandas
- Créer des features métier à partir de données brutes (feature engineering)
- Documenter un processus de traitement de données

4.2 Big Data — ELK

- Déployer et configurer la stack Elasticsearch / Logstash / Grafana
- Créer des mappings Elasticsearch adaptés à un modèle de données
- Indexer des données massives via Logstash
- Construire des dashboards interactifs avec Grafana
- Exécuter des requêtes de recherche full-text

4.3 ETL & Pipelines (Apache Airflow)

- Concevoir et implémenter des DAGs Airflow (Extract, Transform, Load)
- Orchestrer des tasks avec dépendances, branchements et parallélisme
- Gérer les erreurs, retries et notifications dans un pipeline
- Connecter Airflow à des services externes (Elasticsearch)
- Appliquer les bonnes pratiques de production (idempotence, scheduling, monitoring)

5. Modalités d'évaluation

Critère	Pondération	Détail
Pipeline fonctionnel	40%	Le pipeline Airflow s'exécute sans erreur de bout en bout
Qualité du code	20%	Modularité, lisibilité, documentation, bonnes pratiques Python
Dashboard Grafana	20%	Pertinence des visualisations, interactivité, lisibilité
Soutenance orale	20%	Clarté de la présentation, démo live, réponses aux questions

6. Prérequis

- Notions de base en Python (variables, boucles, fonctions, modules)
- Connaissance basique de la ligne de commande (terminal Linux/Mac ou WSL)
- Avoir Docker Desktop installé sur sa machine
- Un éditeur de code (VS Code recommandé)
- Curiosité pour l'univers anime/manga (non obligatoire mais apprécié !)

7. Ressources & liens utiles

- Dataset : github.com/Hernan4444/MyAnimeList-Database
- Kaggle : kaggle.com/datasets/hernan4444/anime-recommendation-database-2020
- Documentation Elasticsearch : elastic.co/guide
- Documentation Airflow : airflow.apache.org/docs
- Docker Compose ELK : github.com/deviantony/docker-elk
- Pandas : pandas.pydata.org/docs